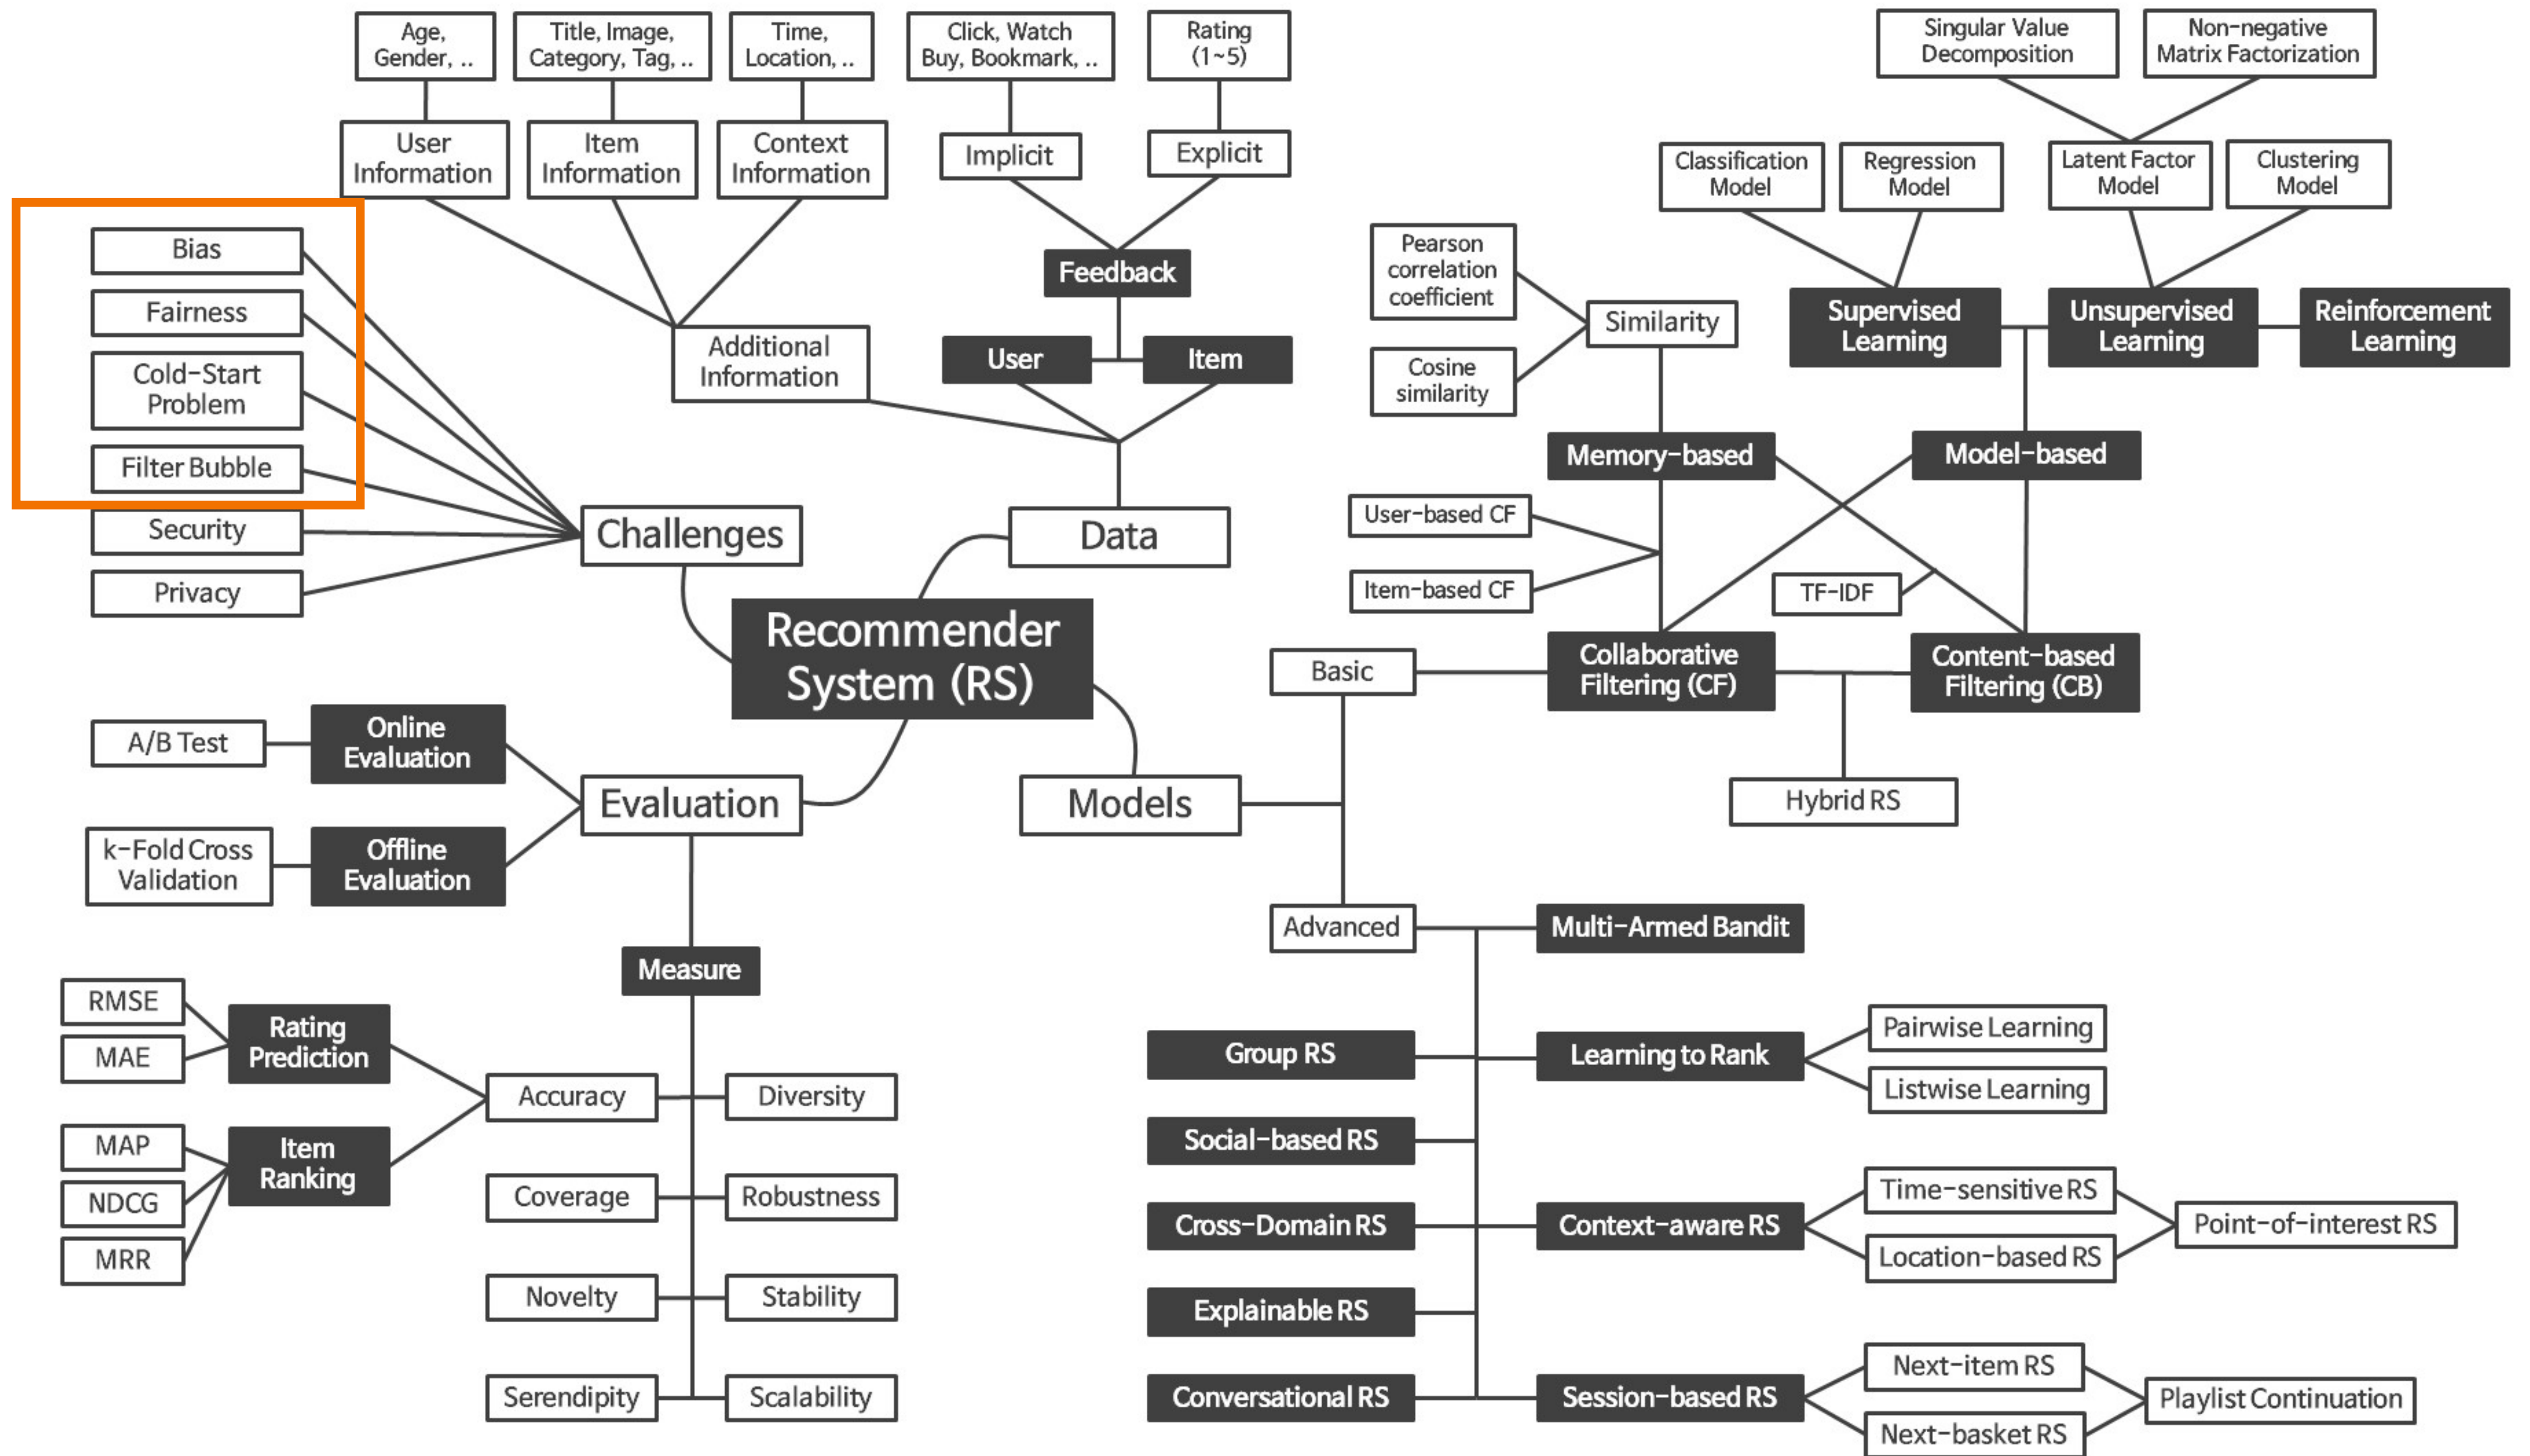


Проблемы индустриальных рекомендательных систем

Осиновсков Илья, 28.04.2025. AI masters.



Проблема холодного старта

Проблема холодного старта

- **Определение:** Невозможность формирования качественных рекомендаций из-за отсутствия данных

Проблема холодного старта

- **Определение:** Невозможность формирования качественных рекомендаций из-за отсутствия данных
- **Холодный старт пользователя:** новый пользователь без истории взаимодействий

Проблема холодного старта

- **Определение:** Невозможность формирования качественных рекомендаций из-за отсутствия данных
- **Холодный старт пользователя:** новый пользователь без истории взаимодействий
- **Холодный старт контента:** новый элемент, с которым еще никто не взаимодействовал

Проблема холодного старта

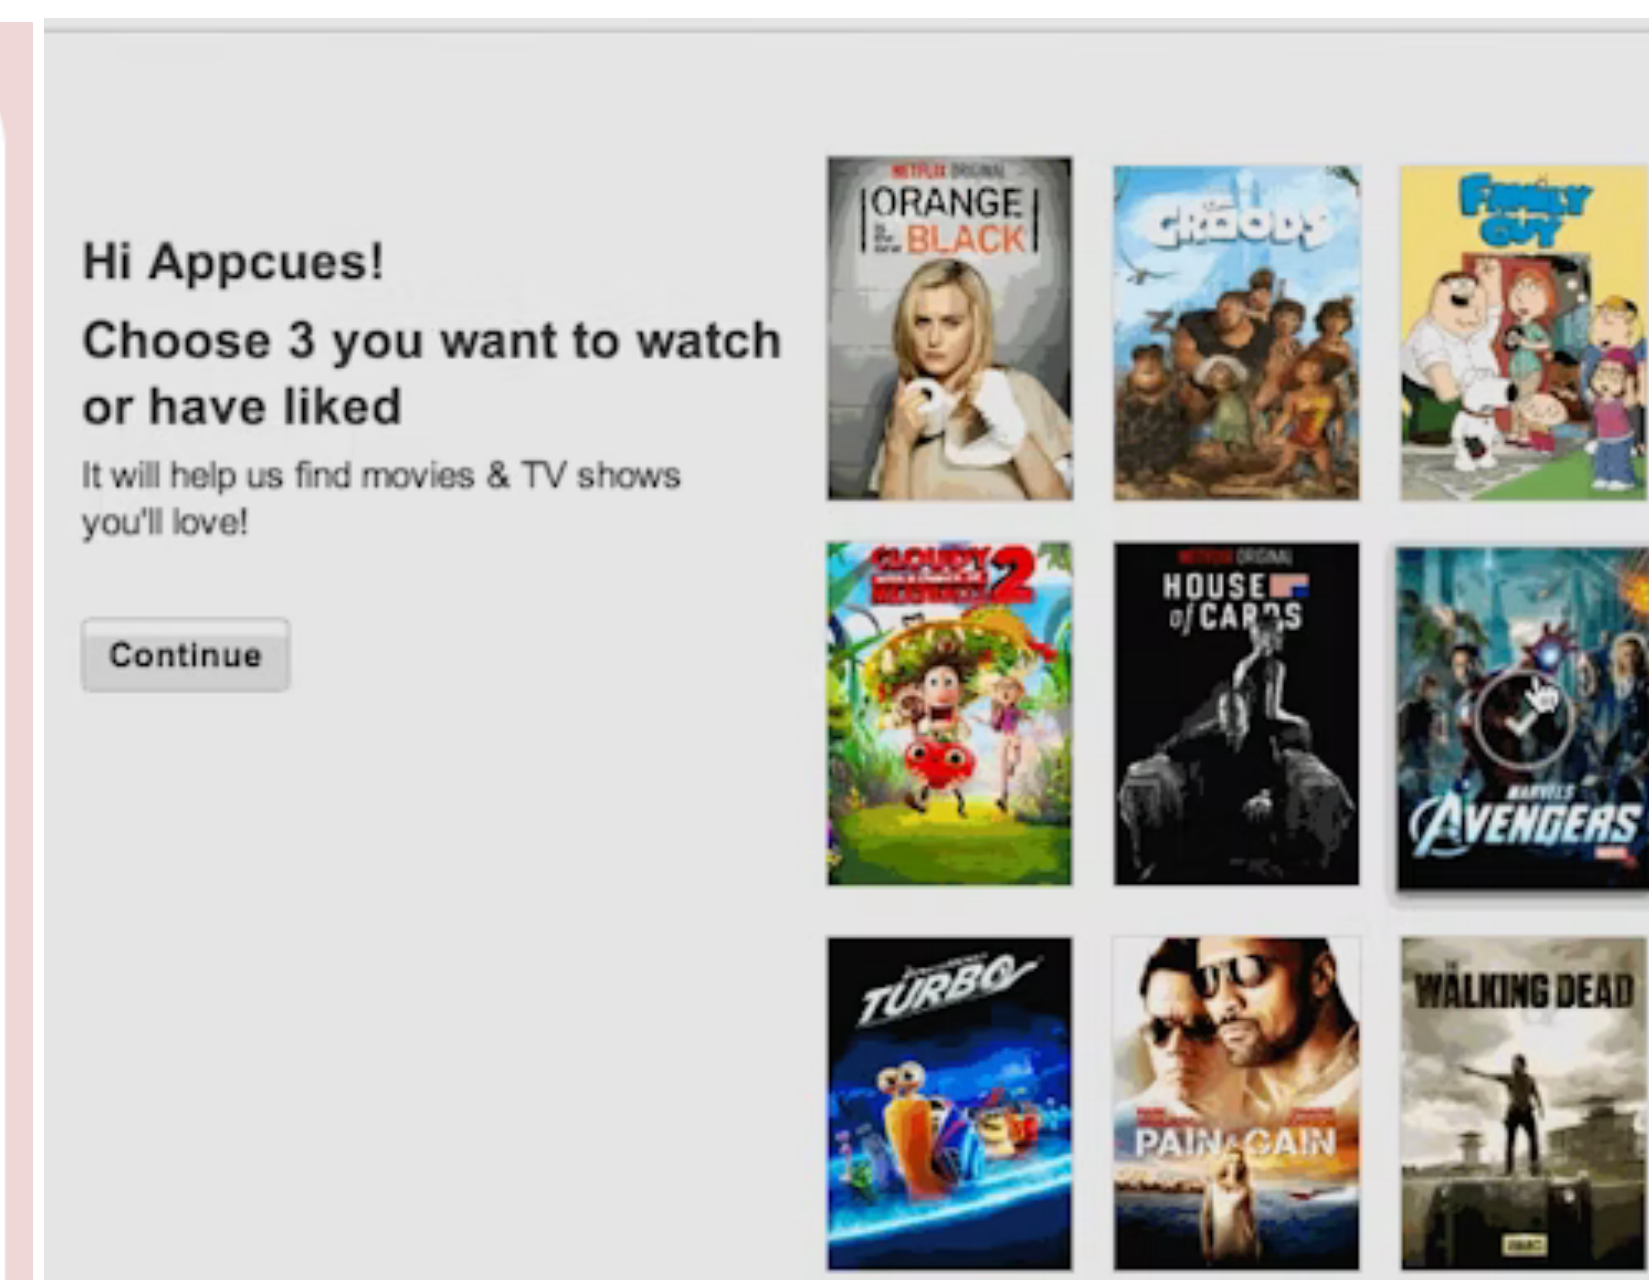
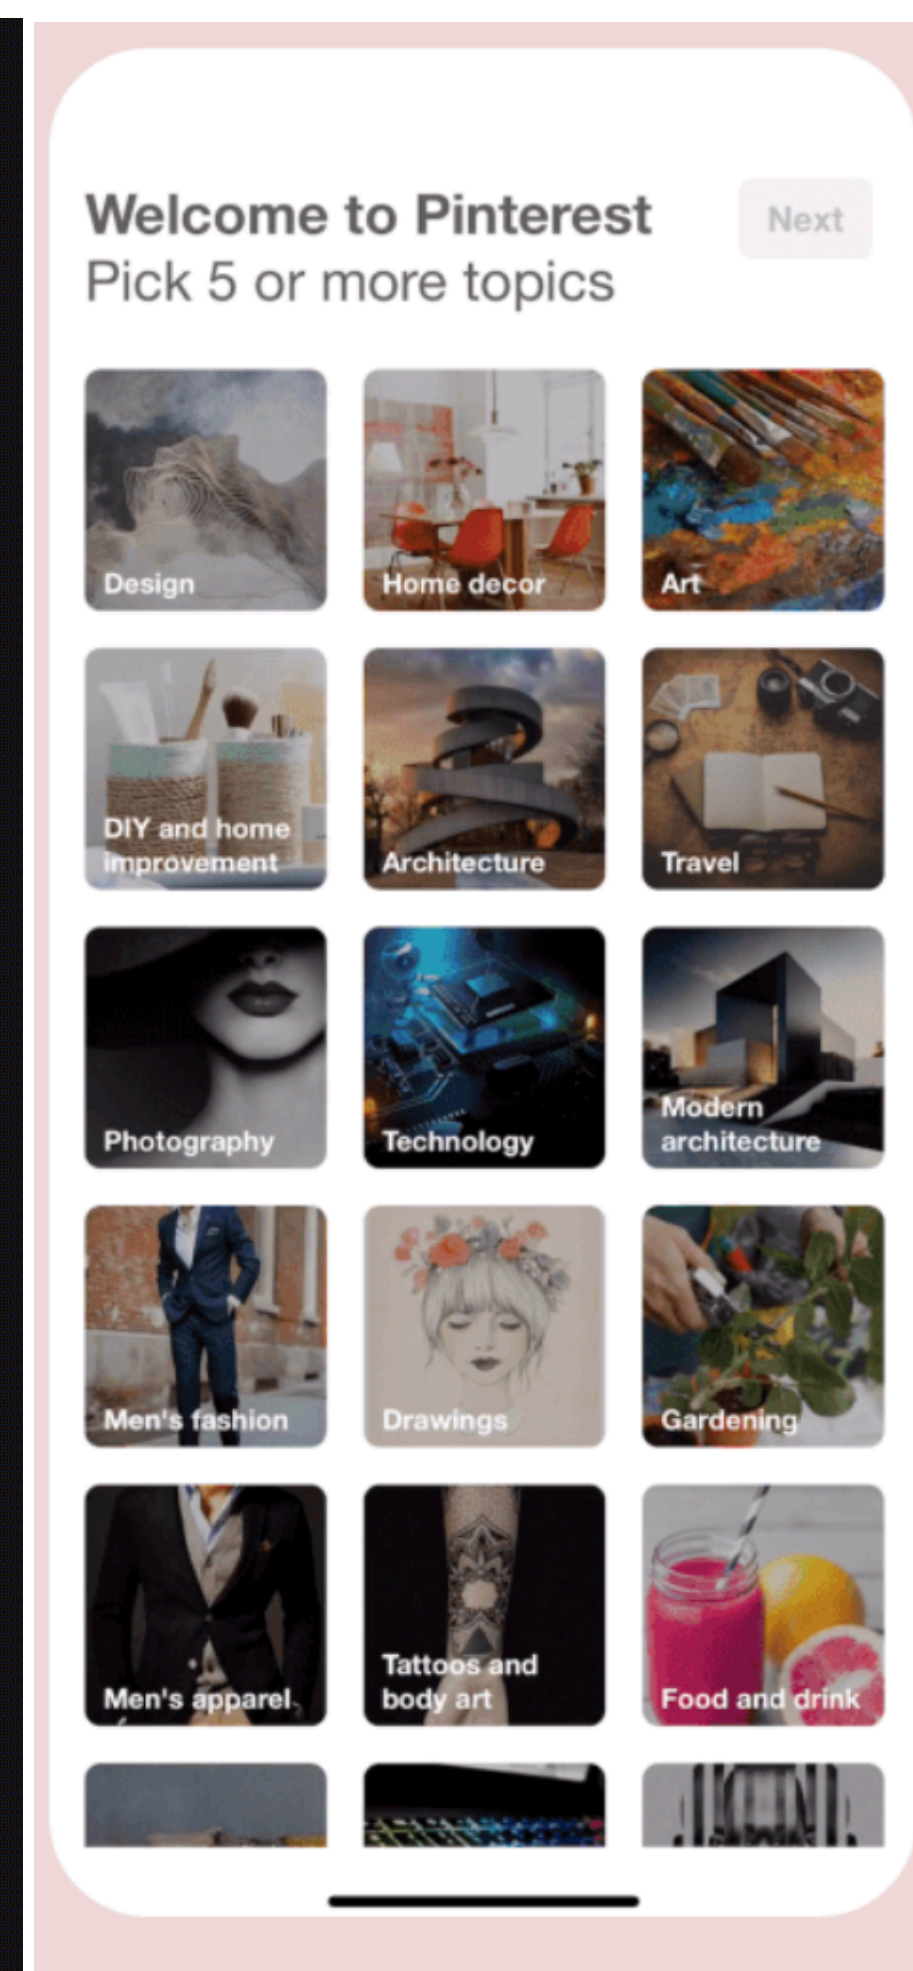
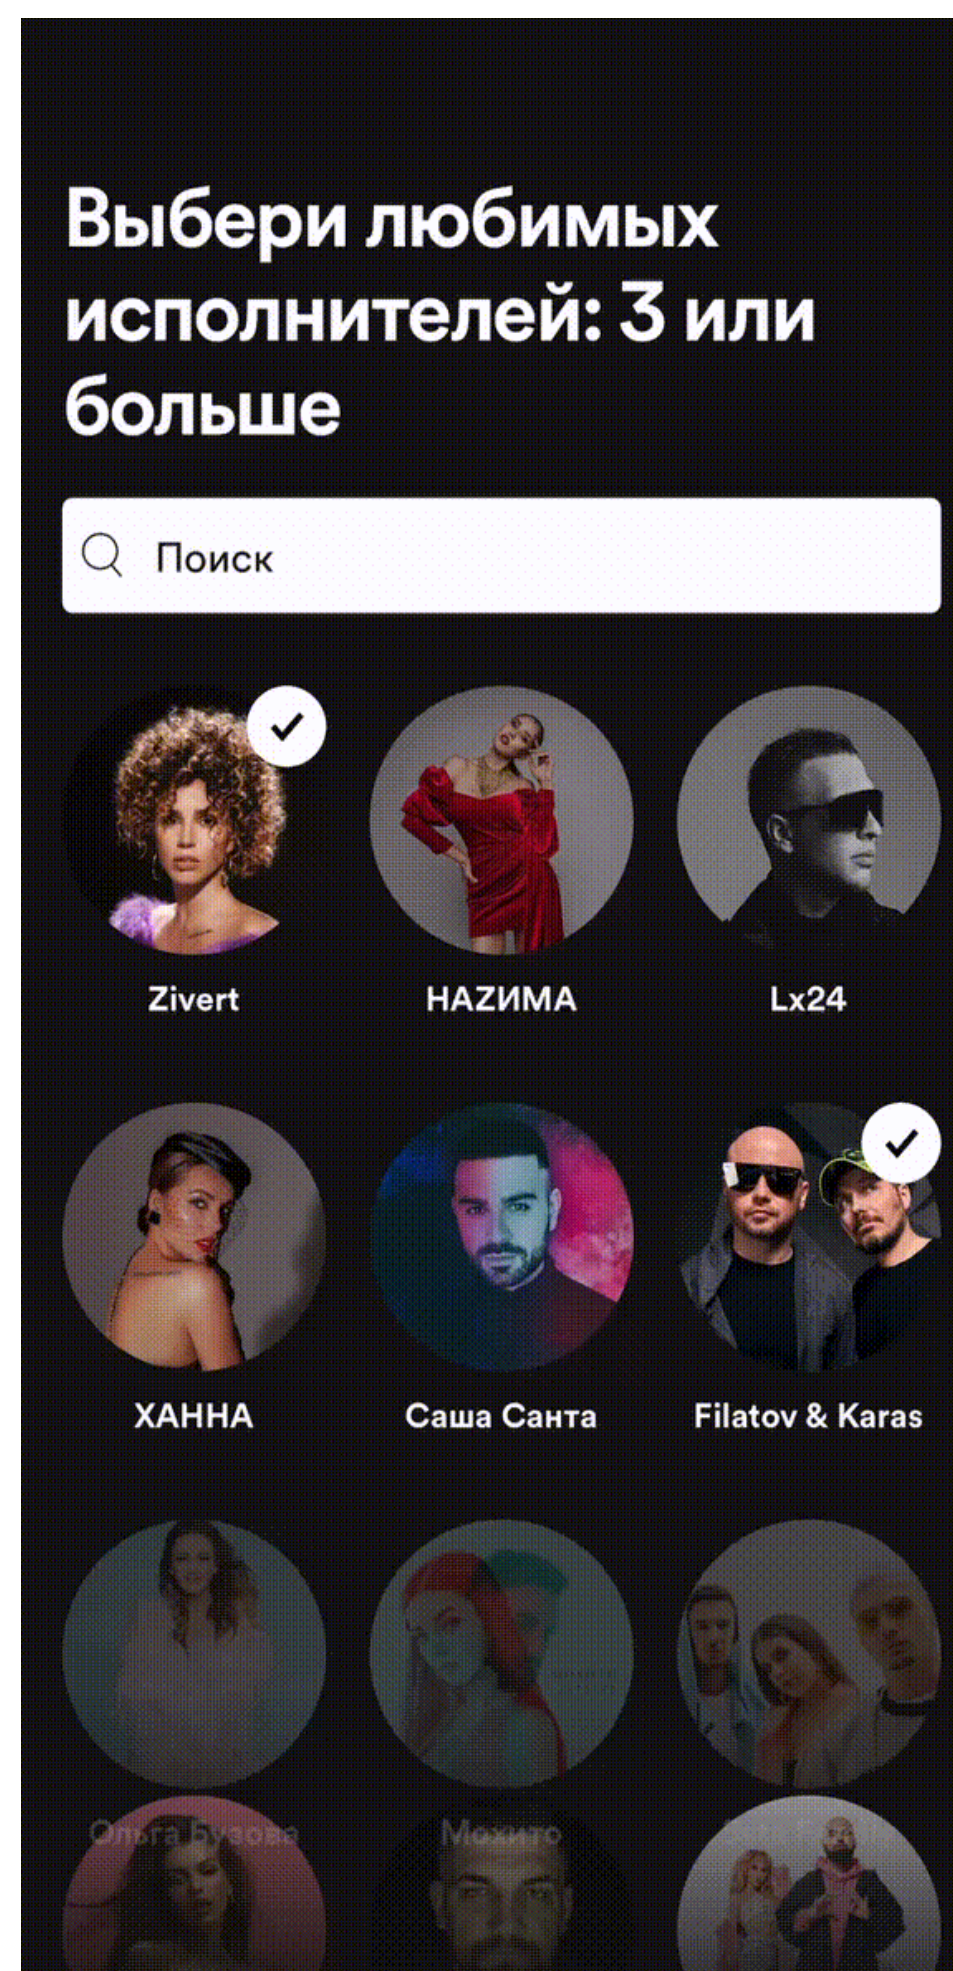
- **Определение:** Невозможность формирования качественных рекомендаций из-за отсутствия данных
- **Холодный старт пользователя:** новый пользователь без истории взаимодействий
- **Холодный старт контента:** новый элемент, с которым еще никто не взаимодействовал
- **Последствия:** низкое качество рекомендаций, снижение вовлеченности

Холодный старт пользователя

Холодный старт пользователя

Явный сбор предпочтений

- онбординг
- КВИЗЫ
- начальные оценки



Холодный старт пользователя

Использование демографии

- пол
- возраст
- локация
- образование
- ...

Холодный старт пользователя

Использование демографии

- **Примеры из индустрии:**
 - **Amazon:** Адаптирует первоначальные рекомендации в зависимости от местоположения пользователя, предлагая сезонные товары, региональные бестселлеры и продукты, популярные в данном регионе.
 - **LinkedIn:** Анализирует указанную должность, компанию и образование для формирования первых рекомендаций по людям, группам и контенту.
 - **Disney+:** Предлагает контент в зависимости от возрастной группы пользователя, выделяя мультфильмы для детей и более серьезный контент для взрослой аудитории.
 - **The New York Times:** Подбирает первоначальные статьи с учетом географического положения читателя, например, больше местных новостей для американской аудитории.

Холодный старт пользователя

Сессионные рекомендации

- Сессионные рекомендации фокусируются на текущем взаимодействии пользователя с системой, а не на долгосрочной истории. Система анализирует действия пользователя в реальном времени и динамически адаптирует рекомендации.

Холодный старт пользователя

Сессионные рекомендации

- **Примеры из индустрии:**
 - **TikTok:** Использует сложные алгоритмы, которые отслеживают время просмотра каждого видео, взаимодействие с ним (лайки, комментарии, сохранения) и мгновенно корректируют контент в ленте. Достаточно 10-15 минут использования для создания высокорелевантных рекомендаций.
 - **Pinterest:** Адаптирует показ пинов на основе того, какие изображения пользователь просматривает и сохраняет в рамках одной сессии, быстро переходя к релевантному контенту.
 - **Booking.com:** Изменяет рекомендуемые отели в режиме реального времени в зависимости от параметров, которые пользователь просматривает (ценовой диапазон, местоположение, рейтинг).
 - **Steam:** Анализирует, какие игры просматривает пользователь, формируя раздел "Рекомендуемое для вас" динамически в рамках одного сеанса.

Холодный старт пользователя

Сессионные рекомендации

- Когда пользователь взаимодействует хотя бы с одним элементом, мы можем применить подход item2item:
 - Рекомендуем товары, которые часто просматриваются вместе с текущим

Холодный старт пользователя

Сессионные рекомендации

- Когда пользователь взаимодействует хотя бы с несколькими элементами, мы можем перейти к более сложным подходам:
 - ALS
 - Нейросети

Холодный старт пользователя

Сессионные рекомендации - ALS

- Вместо полного переобучения модели мы можем адаптировать существующую модель для нового пользователя:
 - **Предварительный этап:** обучаем ALS модель на существующих данных
 - Получаем матрицу латентных факторов предметов P
 - Получаем матрицу латентных факторов пользователей Q
 - **Этап реального времени:** фиксируем факторы предметов P и обновляем только факторы нового пользователя

Холодный старт пользователя

Сессионные рекомендации - ALS

- **Этап реального времени:** фиксируем факторы предметов P и обновляем только факторы нового пользователя
 - Для нового пользователя u с имеющимися рейтингами r_{ui} для предметов i :

Оптимизируем только вектор пользователя $q_u = \arg \min_{q_u} \sum_{i \in I_u} (r_{ui} - p_i^T q_u)^2 + \lambda ||q_u||^2$

где:

- I_u — множество предметов, с которыми взаимодействовал пользователь u
 - p_i — вектор латентных факторов предмета i (фиксированный)
 - λ — параметр регуляризации
- Аналитическое решение: $q_u = (P_{I_u}^T P_{I_u} + \lambda I)^{-1} P_{I_u}^T r_u$

где:

 - P_{I_u} — матрица латентных факторов предметов, с которыми взаимодействовал u
 - r_u — вектор рейтингов пользователя u

Холодный старт пользователя

Сессионные рекомендации

- Использовать модели на последовательностях действий:
 - Bert4Rec
 - SASRec
 - ...
- Смотрите 8 лекцию

Холодный старт пользователя

Социальная авторизация

- Позволяет новым пользователям "импортировать" предпочтения и связи из существующих социальных сетей, создавая первичный набор предпочтений.
- **Примеры из индустрии:**
 - **Goodreads:** При авторизации через Facebook сервис анализирует страницы книг, авторов и издательств, которые пользователь лайкнул, а также получает доступ к предпочтениям друзей, формируя начальные рекомендации по чтению.
 - **Spotify:** Интегрируется с Facebook и другими социальными сетями, что позволяет сразу показывать музыку, популярную среди друзей пользователя, а также автоматически формировать плейлисты на основе общих предпочтений.
 - **Strava:** При подключении через социальные сети сразу предлагает подписаться на друзей, которые уже используют платформу, и показывает популярные маршруты среди этой группы.

Холодный старт пользователя

Активное обучение

- Стратегически выбираем элементы для оценки пользователем, максимизируя информационную ценность каждого взаимодействия.
- **Цель** — быстрое и эффективное формирование точного профиля предпочтений при минимальном количестве запросов.
- **Примеры из индустрии:**
 - **MovieLens:** Вместо случайного набора популярных фильмов система выбирает те, которые помогут точнее определить вкусы — например, фильмы, разделяющие пользователей на четкие группы по предпочтениям.
 - **StitchFix:** Применяет адаптивные опросники, где каждый следующий вопрос о стиле одежды зависит от предыдущих ответов, что позволяет быстро сузить диапазон предпочтений пользователя.
 - **Pandora:** Использует специально подобранную последовательность треков для оценки, алгоритмически выбирая композиции, покрывающие различные музыкальные характеристики.
 - **Hinge:** Датинговое приложение просит оценить специально подобранные профили, чтобы определить предпочтения в партнерах по ключевым параметрам.

Холодный старт пользователя

- **Явный сбор предпочтений:** онбординг, квизы, начальные оценки
- **Использование демографии:** рекомендации на основе возраста, локации, образования
- **Сессионные рекомендации:** использование текущих действий пользователя
- **Социальная авторизация:** заимствование данных из социальных профилей
- **Активное обучение:** стратегический выбор элементов для оценки пользователем

Холодный старт контента

Холодный старт контента

Контентная фильтрация

- Опирается на структурированные и неструктурированные метаданные, позволяя рекомендовать новые элементы без истории взаимодействий, на основе их характеристик и соответствия профилям пользователей.

Холодный старт контента

Контентная фильтрация

- Опирается на структурированные и неструктурированные метаданные, позволяя рекомендовать новые элементы без истории взаимодействий, на основе их характеристик и соответствия профилям пользователей.
- **Примеры из индустрии:**
 - **Netflix:** Использует более 3000 микро-жанров и тегов для каждого фильма или сериала, включая такие детальные характеристики как "Криминальные триллеры с сильной женской ролью", что позволяет рекомендовать новые релизы, соответствующие профилям пользователей.
 - **Spotify:** Классифицирует новые треки по 400+ музыкальным характеристикам, включая темп, инструментовку, настроение и энергичность, что позволяет включать новинки в плейлисты без предварительных прослушиваний.
 - **Steam:** Анализирует метаданные новых игр (жанр, графический стиль, однопользовательский/многопользовательский режим) для соотнесения с предпочтениями геймеров.

Холодный старт контента

Анализ текста и изображений

- Автоматическое извлечение признаков использует методы компьютерного зрения, обработки естественного языка и аудиоанализа для создания векторных представлений нового контента без необходимости ручной разметки метаданных.

Холодный старт контента

Анализ текста и изображений

- Автоматическое извлечение признаков использует методы компьютерного зрения, обработки естественного языка и аудиоанализа для создания векторных представлений нового контента без необходимости ручной разметки метаданных.
- **Примеры из индустрии:**
 - **YouTube:** Автоматически анализирует содержание видео, извлекая информацию о визуальных сценах, транскрибирует речь и распознает объекты, что позволяет предлагать новый контент до накопления достаточного количества просмотров.
 - **Pinterest:** Использует системы компьютерного зрения для автоматического понимания содержания новых изображений, определяя объекты, цветовые схемы, стили и композицию для точной категоризации и рекомендации.
 - **Medium:** Применяет NLP-модели для анализа новых статей, автоматически определяя тематику, сложность текста, эмоциональный тон и ключевые концепции.

Холодный старт контента

Стратегии первоначального продвижения

- Временное повышение видимости нового контента для преодоления "барьера первого взаимодействия" путем сознательного увеличения его показов для формирования начальной обратной связи и данных о взаимодействиях.

Холодный старт контента

Стратегии первоначального продвижения

- Временное повышение видимости нового контента для преодоления "барьера первого взаимодействия" путем сознательного увеличения его показов для формирования начальной обратной связи и данных о взаимодействиях.
- **Механизмы реализации:**
 - **Управляемая экспозиция:** представление нового контента определенному проценту пользователей независимо от их предыдущих предпочтений
 - **Разделение интерфейса:** создание специальных разделов "Новинки" или "Попробуйте что-то новое»
 - **Временное повышение рейтинга:** искусственное увеличение релевантности нового контента в алгоритмах ранжирования

Холодный старт контента

Стратегии первоначального продвижения

- **Примеры из индустрии:**
 - **TikTok:** Использует систему "контролируемого тестирования", когда новое видео показывается небольшой выборке пользователей (~300-500 человек). Алгоритм оценивает коэффициент завершения просмотра, время задержки, количество взаимодействий, и если метрики положительные, постепенно увеличивает охват.
 - **Amazon Prime Video:** Выделяет раздел "Новые релизы" с особым дизайном и стратегически размещает его на домашнем экране всех пользователей, гарантируя видимость новому контенту.
 - **Apple Podcasts:** Использует кураторские списки "New & Noteworthy" для продвижения новых подкастов, давая им шанс получить первоначальные прослушивания и отзывы.
 - **Новостные агрегаторы:** Временно повышает видимость новостных статей по новым событиям для сбора начальных данных о взаимодействии.

Холодный старт контента

Трансферное обучение

- Основано на принципе переноса знаний о взаимодействиях пользователей с существующими элементами на похожие новые элементы, что позволяет "заимствовать" начальные паттерны потребления.

Холодный старт контента

Трансферное обучение

- Основано на принципе переноса знаний о взаимодействиях пользователей с существующими элементами на похожие новые элементы, что позволяет "заимствовать" начальные паттерны потребления.
- **Примеры из индустрии:**
 - **Amazon Books:** Когда новая книга автора появляется в каталоге, система автоматически применяет данные о взаимодействиях пользователей с предыдущими книгами этого автора для начального позиционирования.
 - **YouTube Music:** Использует информацию о прослушивании предыдущих треков артиста для создания "прогнозируемой аудитории" для нового релиза, целенаправленно предлагая его фанатам исполнителя.
 - **HBO Max:** Применяет данные о просмотрах предыдущих сезонов или похожих шоу для формирования первоначальной аудитории для новых сериалов.
 - **Steam:** Анализирует поведение пользователей с играми одного разработчика, жанра или серии для построения начальных моделей рекомендаций для новых релизов.

Холодный старт контента

- **Контентная фильтрация:** использование метаданных и характеристик
- **Анализ текста и изображений:** автоматическое извлечение признаков
- **Стратегии первоначального продвижения:** временное повышение ВИДИМОСТИ
- **Трансферное обучение:** использование данных похожего контента

Смещения в рекомендательных системах

Смещения в рекомендательных системах

- Что такое смещения (biases):
 - Систематические отклонения в рекомендациях, которые приводят к непропорциональному представлению определенных групп, идей или продуктов
 - Несоответствие между целевой функцией рекомендательной системы и реальными интересами пользователей

Смещения в рекомендательных системах

- **Popularity Bias:** предпочтение популярных элементов

Смещения в рекомендательных системах

- **Popularity Bias:** предпочтение популярных элементов
- **Position Bias:** предвзятость к позиции элемента в интерфейсе

Смещения в рекомендательных системах

- **Popularity Bias:** предпочтение популярных элементов
- **Position Bias:** предвзятость к позиции элемента в интерфейсе
- **Selection Bias:** неравномерное представление данных о взаимодействиях

Смещения в рекомендательных системах

- **Popularity Bias:** предпочтение популярных элементов
- **Position Bias:** предвзятость к позиции элемента в интерфейсе
- **Selection Bias:** неравномерное представление данных о взаимодействиях
- **Конформное смещение:** влияние социального одобрения на оценки

Смещения в рекомендательных системах

- **Popularity Bias:** предпочтение популярных элементов
- **Position Bias:** предвзятость к позиции элемента в интерфейсе
- **Selection Bias:** неравномерное представление данных о взаимодействиях
- **Конформное смещение:** влияние социального одобрения на оценки
- **Проблема:** искажение данных, снижение разнообразия, информационные пузыри

Popularity bias

- **Пример:** В музыкальном стриминге хиты получают непропорционально больше рекомендаций, чем треки нишевых артистов, даже если последние могут больше соответствовать вкусам конкретного пользователя.
- **Методы решения:**
 - Регуляризация на основе популярности
 - Переранжирование рекомендаций для увеличения разнообразия
 - Явное введение квот для менее популярного контента

Position bias

- **Пример:** Первый результат поиска получает намного больше кликов, даже если второй или третий результаты более релевантны запросу пользователя.
- **Методы решения:**
 - Рандомизация позиций для сбора несмещенных данных
 - Модели пропускания кликов (click propensity models)
 - Inverse propensity scoring для коррекции смещений при обучении

Position bias

Рандомизация позиций для сбора несмещенных данных

- **Полная рандомизация:**
Полное перемешивание результатов для некоторой доли пользователей или запросов.
 - Преимущества:
 - Полное устранение позиционного смещения
 - Простота реализации
 - Недостатки:
 - Значительное ухудшение пользовательского опыта
- **Частичная рандомизация:**
Рандомизация в пределах групп близких по релевантности результатов.

Position bias

Модели пропускания кликов (Click Propensity Models)

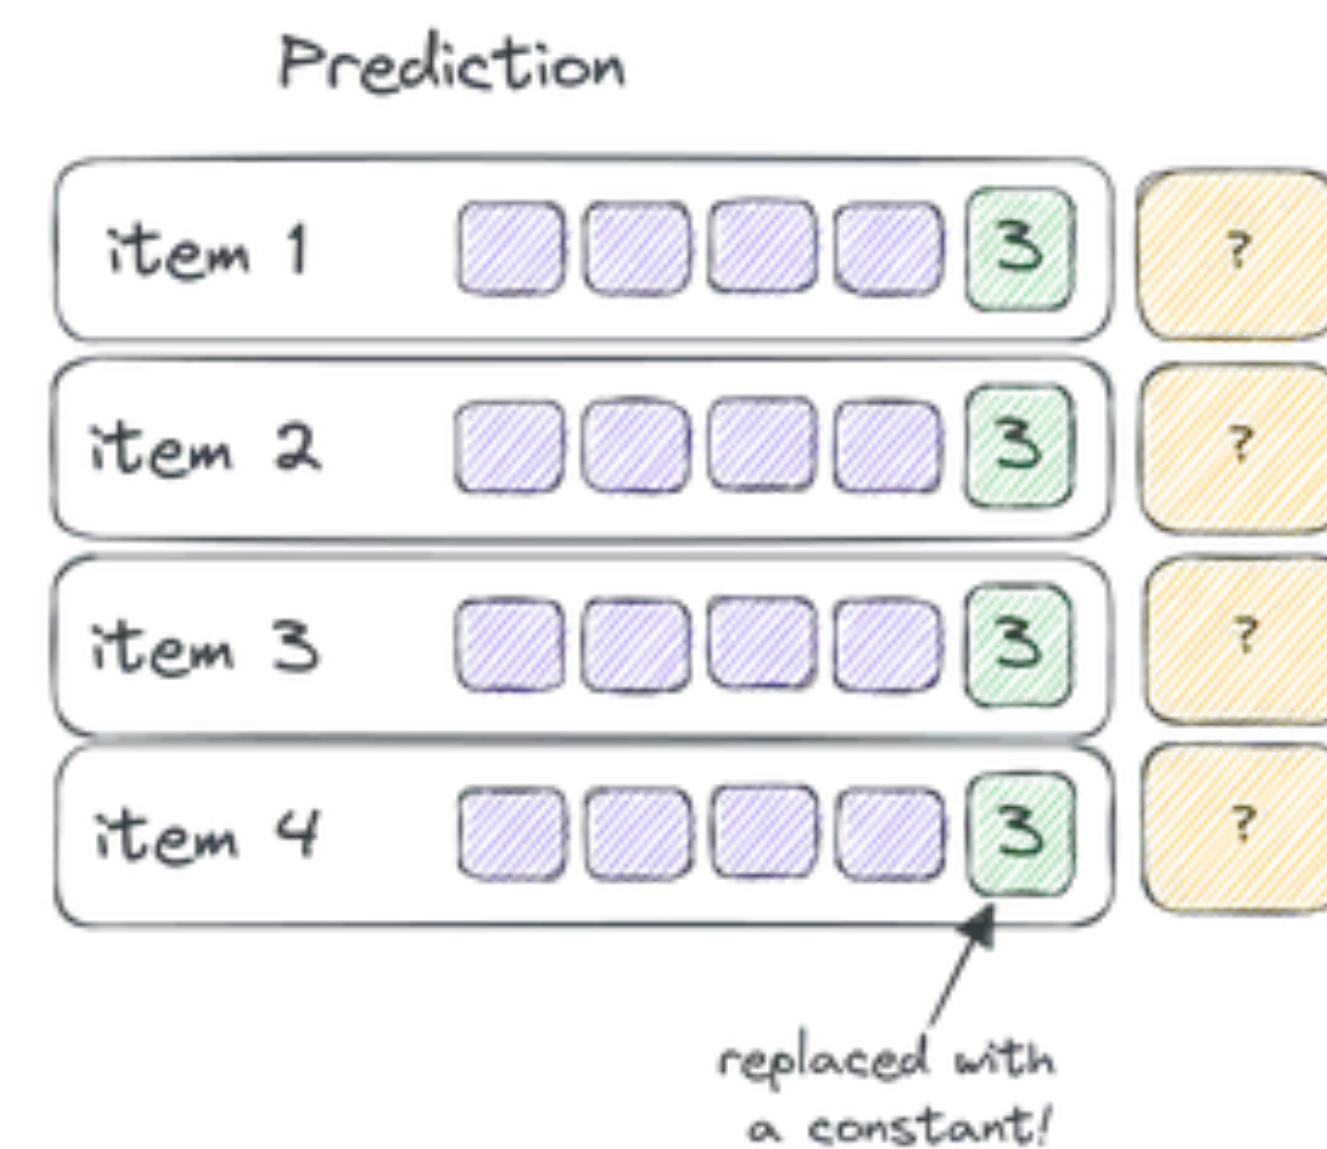
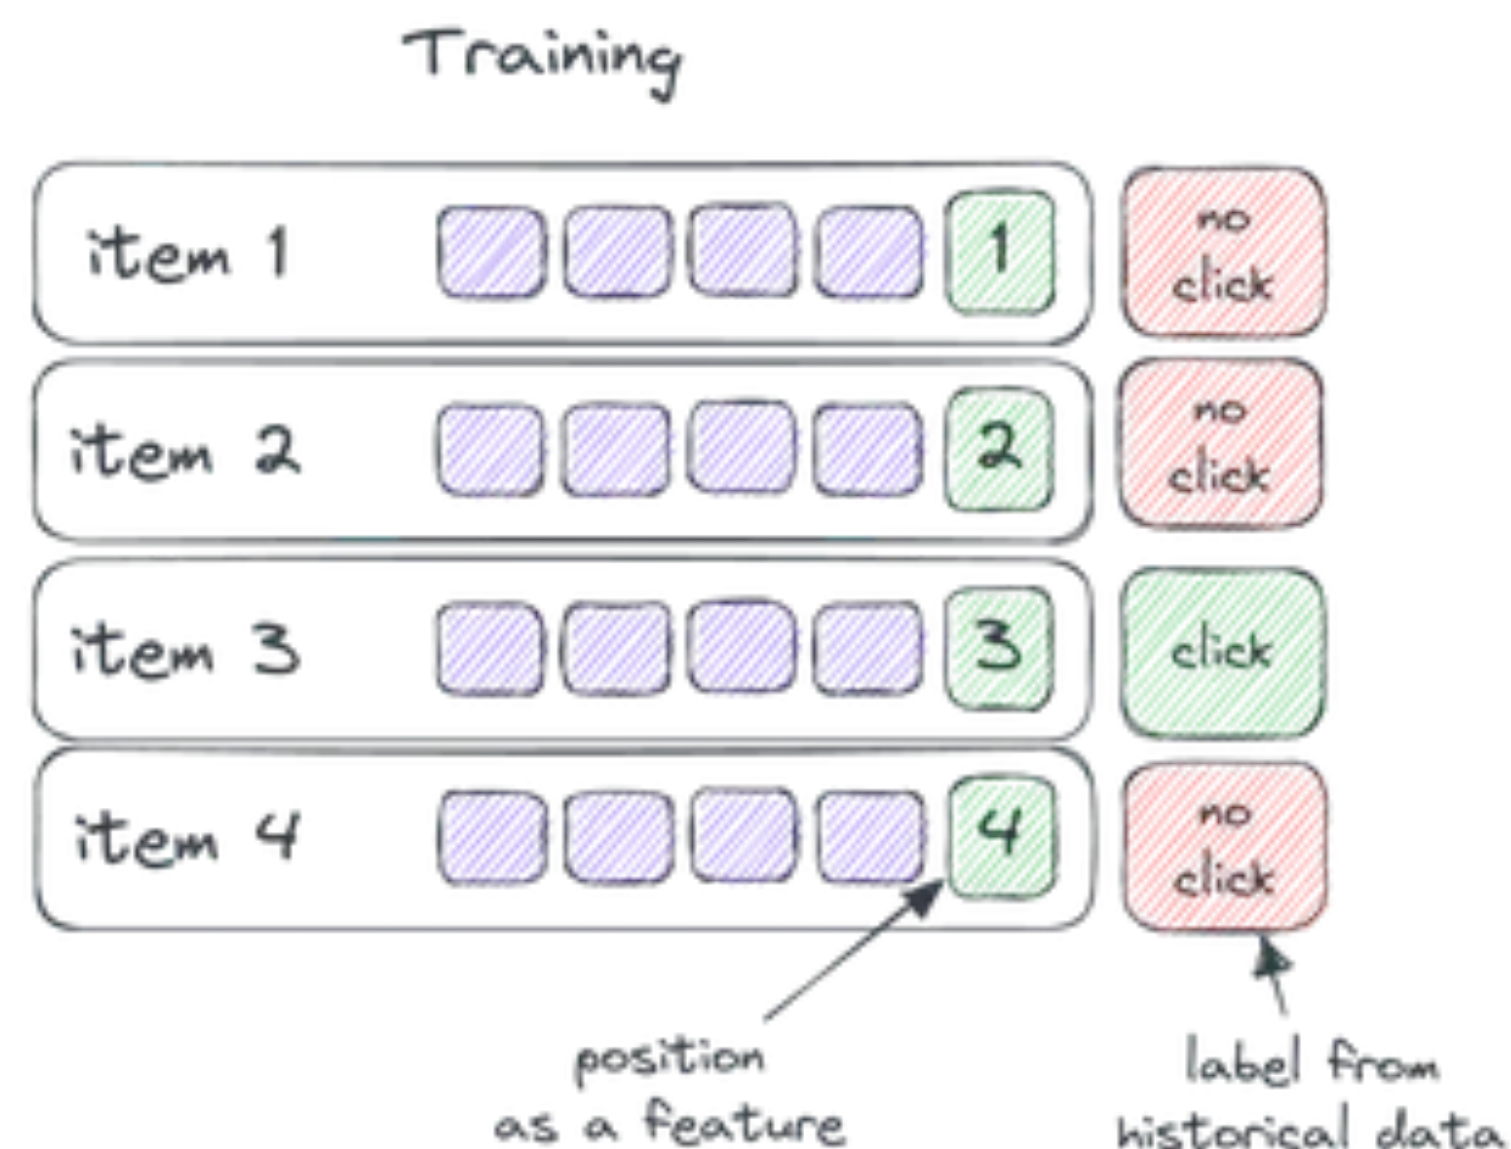
- **Определение:** Модели пропускания кликов оценивают вероятность того, что пользователь заметит и рассмотрит элемент в определенной позиции, независимо от его релевантности.
- Вероятностная модель клика:
$$P(\textit{click} \mid d, q, r) = P(\textit{click} \mid d, q) \cdot P(\textit{view} \mid r)$$

где:
 - d — документ или элемент
 - q — запрос пользователя
 - r — позиция (ранг) в выдаче
 - $P(\textit{view} \mid r)$ — вероятность просмотра позиции r (propensity)

Position bias

Обучение с учетом позиции

- **Обучение:**
 - Проставляем позицию в признаки
- **Применение:**
 - Заменяем позицию константным значением



Selection bias

- **Пример:** В системе рекомендации фильмов пользователи обычно смотрят и оценивают фильмы, которые им интересны, оставляя неясным отношение к фильмам, которые они не выбрали.
- **Методы решения:**
 - Негативный сэмплинг
 - Техники заполнения пропущенных данных

Selection bias

Негативный семплинг

- Равномерный
- Популярностно-взвешенный
- На основе сходства
- ...

Exploration-exploitation trade off

Exploration-exploitation trade off

- **Exploitation:** рекомендовать то, что с высокой вероятностью понравится

Exploration-exploitation trade off

- **Exploitation:** рекомендовать то, что с высокой вероятностью понравится
- **Exploration:** исследовать новые возможности для получения информации

Exploration-exploitation trade off

- **Exploitation:** рекомендовать то, что с высокой вероятностью понравится
- **Exploration:** исследовать новые возможности для получения информации
- **Дилемма:**
 - слишком много exploitation ведет к «фильтр-пузырям»

Exploration-exploitation trade off

- **Exploitation:** рекомендовать то, что с высокой вероятностью понравится
- **Exploration:** исследовать новые возможности для получения информации
- **Дилемма:**
 - слишком много exploitation ведет к «фильтр-пузырям»
 - слишком много exploration: ухудшение пользовательского опыта

Exploration-exploitation trade off

- **Exploitation:** рекомендовать то, что с высокой вероятностью понравится
- **Exploration:** исследовать новые возможности для получения информации
- **Дилемма:**
 - слишком много exploitation ведет к «фильтр-пузырям»
 - слишком много exploration: ухудшение пользовательского опыта
- **Ключевой вопрос:** как найти оптимальный баланс?

Фильтр-пузыри и их последствия

- **Определение:** изоляция контента из-за персонализированных алгоритмов
- **Проблемы:**
 - Ограничение разнообразия контента
 - Усиление существующих убеждений
 - Идеологическая/информационная поляризация
- **Решения:**
 - Намеренная диверсификация
 - Serendipity-ориентированные алгоритмы
 - Пользовательский контроль над параметрами рекомендаций

Алгоритмы для exploration-exploitation

Алгоритмы для exploration-exploitation

ϵ -greedy

- Основной принцип
 - С вероятностью $1 - \epsilon$: выбираем лучшие элементы на основе текущей модели (использование)
 - С вероятностью ϵ : выбираем случайные элементы (исследование)

Алгоритмы для exploration-exploitation

ϵ -greedy

- **Основной принцип**

- С вероятностью $1 - \epsilon$: выбираем лучшие элементы на основе текущей модели (использование)
- С вероятностью ϵ : выбираем случайные элементы (исследование)

- **Математическая формулировка**

- Вероятность рекомендации элемента i пользователю u :

$$P(i | u) = \begin{cases} 1 - \epsilon + \frac{\epsilon}{|I|}, & \text{если } i = \arg \max_j \hat{r}_{uj} \\ \frac{\epsilon}{|I|}, & \text{иначе} \end{cases}$$

где \hat{r}_{uj} - предсказанная релевантность элемента i для пользователя u

Алгоритмы для exploration-exploitation

Upper Confidence Bound (UCB):

- **Ключевая идея:** Вместо случайного исследования, как в ϵ -greedy, UCB систематически выбирает элементы с наибольшим потенциалом, балансируя между:
 - Оценкой ожидаемой награды (использование)
 - Уровнем неопределенности этой оценки (исследование)
- **Математическая формулировка:**

Для каждого элемента i и пользователя u вычисляется UCB-оценка: $UCB_{ui} = \hat{r}_{ui} + c \cdot \sqrt{\frac{2 \ln n}{n_i}}$

где:

- \hat{r}_{ui} - текущая оценка релевантности элемента i для пользователя u
- n - общее количество взаимодействий
- n_i - количество взаимодействий с элементом i
- c - параметр, контролирующий уровень исследования

Алгоритмы для exploration-exploitation

- Есть еще:
 - Семплирования Томпсона
 - Контекстные многорукие бандиты

Вопросы